# РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ

Факультет физико-математических и естественных наук

Кафедра информационных технологий

# ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 2

Дисциплина: Методы машинного обучения

Студент: Шалыгин Георгий

Группа: НФИ-02

## **Москва 2023**

## Вариант № 18

**1.** Загрузите заданный в индивидуальном задании набор данных из **Tensorflow Datasets**, включая указанные в задании независимый признак и зависимый признак (отклик).

Набор данных: forest\_fires.

Независимая переменная: features/FFMC.

Зависимая переменная: features/temp

## In [ ]:

```
import tensorflow_datasets as tfds
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

#### In [8]:

```
ds = tfds.load("forest_fires", split='train')
df = tfds.as_dataframe(ds)
df.info()
```

<class 'tensorflow\_datasets.core.as\_dataframe.StyledDataFrame'>
RangeIndex: 517 entries, 0 to 516

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	area	517 non-null	float32
1	features/DC	517 non-null	float32
2	features/DMC	517 non-null	float32
3	features/FFMC	517 non-null	float32
4	features/ISI	517 non-null	float32
5	features/RH	517 non-null	float32
6	features/X	517 non-null	uint8
7	features/Y	517 non-null	uint8
8	features/day	517 non-null	int64
9	features/month	517 non-null	int64
10	features/rain	517 non-null	float32

```
11 features/temp 517 non-null f
12 features/wind 517 non-null f
dtypes: float32(9), int64(2), uint8(2)
                                      float32
memory usage: 27.4 KB
In [9]:
#уберем выбросы
df = df[df['features/FFMC'] > 80]
 1. Решите задачу полиномиальной регрессии для степени полинома, указанной в индивидуальном задании,
   при помощи нейронной сети с одним нейроном и оцените качество полученной модели по показателю,
   указанному в индивидуальном задании.
   Степень полинома: 3.
   Показатель качества регрессии - MSE (mean squared error)
In [10]:
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
import tensorflow as tf
In [11]:
x = df['features/FFMC']
y = df['features/temp']
In [12]:
from sklearn.preprocessing import PolynomialFeatures
poly = PolynomialFeatures(degree=3)
X = poly.fit transform(pd.DataFrame(x))
Χ
Out[12]:
array([[1.0000000e+00, 9.6099998e+01, 9.2352100e+03, 8.8750369e+05],
       [1.0000000e+00, 9.0500000e+01, 8.1902500e+03, 7.4121762e+05],
       [1.0000000e+00, 9.4300003e+01, 8.8924902e+03, 8.3856188e+05],
       [1.0000000e+00, 9.0000000e+01, 8.1000000e+03, 7.2900000e+05],
       [1.0000000e+00, 8.9400002e+01, 7.9923604e+03, 7.1451700e+05],
       [1.0000000e+00, 9.1599998e+01, 8.3905596e+03, 7.6857525e+05]],
      dtype=float32)
In [13]:
model = Sequential(Dense(1, input shape=(4,)))
model.summary()
Model: "sequential 1"
 Layer (type)
                              Output Shape
                                                         Param #
______
                              (None, 1)
 dense 1 (Dense)
Total params: 5
Trainable params: 5
Non-trainable params: 0
In [14]:
model.compile(loss='mse', optimizer=tf.keras.optimizers.Adam(learning rate=0.01))
history0 = model.fit(X, y, epochs=100, verbose=1, validation split = 0.2)
```

```
Epoch 1/100
13/13 [=====
   2973795.2500
Epoch 2/100
433640.0000
Epoch 3/100
7498.7500
Epoch 4/100
402.1875
Epoch 5/100
66.6328
Epoch 6/100
90.0703
Epoch 7/100
.4219
Epoch 8/100
8562
Epoch 9/100
590
Epoch 10/100
163
Epoch 11/100
382
Epoch 12/100
432
Epoch 13/100
920
Epoch 14/100
250
Epoch 15/100
355
Epoch 16/100
371
Epoch 17/100
875
Epoch 18/100
Epoch 19/100
975
Epoch 20/100
817
Epoch 21/100
259
Epoch 22/100
585
Epoch 23/100
561
Epoch 24/100
942
```

```
Epoch 25/100
13/13 [======
    =========== ] - 0s 5ms/step - loss: 3412.7820 - val loss: 2597.7
952
Epoch 26/100
843
Epoch 27/100
358
Epoch 28/100
391
Epoch 29/100
Epoch 30/100
680
Epoch 31/100
698
Epoch 32/100
745
Epoch 33/100
147
Epoch 34/100
376
Epoch 35/100
187
Epoch 36/100
903
Epoch 37/100
027
Epoch 38/100
696
Epoch 39/100
823
Epoch 40/100
824
Epoch 41/100
044
Epoch 42/100
Epoch 43/100
282
Epoch 44/100
435
Epoch 45/100
176
Epoch 46/100
226
Epoch 47/100
188
Epoch 48/100
722
```

```
Epoch 49/100
13/13 [======
   535
Epoch 50/100
099
Epoch 51/100
671
Epoch 52/100
312
Epoch 53/100
937
Epoch 54/100
849
Epoch 55/100
744
Epoch 56/100
710
Epoch 57/100
300
Epoch 58/100
722
Epoch 59/100
880
Epoch 60/100
563
Epoch 61/100
892
Epoch 62/100
019
Epoch 63/100
381
Epoch 64/100
244
Epoch 65/100
805
Epoch 66/100
201
Epoch 67/100
426
Epoch 68/100
798
Epoch 69/100
837
Epoch 70/100
774
Epoch 71/100
169
Epoch 72/100
828
```

```
Epoch 73/100
13/13 [=======
   913
Epoch 74/100
751
Epoch 75/100
948
Epoch 76/100
921
Epoch 77/100
548
Epoch 78/100
086
Epoch 79/100
617
Epoch 80/100
612
Epoch 81/100
861
Epoch 82/100
176
Epoch 83/100
234
Epoch 84/100
347
Epoch 85/100
598
Epoch 86/100
454
Epoch 87/100
062
Epoch 88/100
253
Epoch 89/100
554
Epoch 90/100
Epoch 91/100
832
Epoch 92/100
871
Epoch 93/100
440
Epoch 94/100
514
Epoch 95/100
432
Epoch 96/100
196
```

#### In [15]:

MSE = 2947.633663366337

Как видно, модель обучилась до какого-то предела (локального минимума?).


1. Постройте кривые обучения с зависимостью от количества эпох.

## In [20]:

```
def plot_loss(history):
   plt.plot(history.history['loss'], label='loss')
   plt.plot(history.history['val_loss'], label='val_loss')
   plt.ylim([0, max(history.history['loss'])*0.5])
   plt.xlabel('Эпохи обучения')
   plt.ylabel('Ошибка')
   plt.legend()
   plt.grid(True)
```

### In [21]:

```
plot_loss(history0)
```



1. Визуализируйте точки набора данных на плоскости в виде диаграммы рассеяния (ось X - независимый

признак, ось Y – зависимый признак), а также линию регрессии (другим цветом), подписывая оси и рисунок.

#### In [23]:


```
x = np.array(x)
y_pred = np.array(y_pred)
```

#### In [25]:

```
plt.scatter(x, y, label='data')
plt.plot(np.sort(x), y_pred[np.argsort(x)], c='r', lw=3, label='regression');
plt.xlabel('features/FFMC')
plt.ylabel('features/temp')
plt.title('Полиномаильная регрессия')
plt.legend()
```

#### Out[25]:

<matplotlib.legend.Legend at 0x7fea14f24280>



ну, тут уж как поулчилось...

1. Определите в исходном наборе данных признак (отличный от независимого и зависимого признаков), принимающий непрерывные значения и имеющий свойства, указанные в индивидуальном задании. Доп. признак: имеющий минимальную корреляцию с независимой переменной.

area: 0.040062

#### In [26]:

```
# оставим непрерывные df_new = df.drop(['features/X', 'features/Y', 'features/day', 'features/month'], axis=1)
```

### In [27]:

```
np.abs(df_new.corrwith(df['features/FFMC']))
```

### Out[27]:

```
area 0.040062 features/DC 0.443239
```

```
features/DMC 0.490669
features/FFMC 1.000000
features/ISI 0.669626
features/RH 0.252776
features/rain 0.095590
features/temp 0.594506
dtype: float64
```

1. Визуализируйте этот признак в соответствии с индивидуальным заданием. Визуализация доп. признака – эмпирическая плотность распределения

#### In [28]:

```
def ECDF(data, x):
    counter = 0
    for v in data:
        if v <= x:
            counter += 1
    return counter / len(data)

samples = df['area'] # sepal length
    npoints = 500
    dx = (samples.max()-samples.min())/npoints


xlist = [samples.min()+dx*i for i in range(npoints)]
ylist = [ECDF(samples, x) for x in xlist]

df_ECDF = pd.DataFrame(ylist, columns=['V0'],index=xlist)
df_ECDF.plot.line(title='График эмпирической функции распределения признака area', xlabel
='area', ylabel='ECDF(area)')
```

#### Out[28]:

<Axes: title={'center': 'График эмпирической функции распределения признака area'}, xlabe
l='area', ylabel='ECDF(area)'>

## График эмпирической функции распределения признака area



1. Сформируйте набор входных данных из двух признаков набора данных (независимый признак и определенный признак), создайте и адаптируйте нормализующий слой **Tensorflow** для двух признаков.

```
X = df[['features/FFMC', 'area']]
X.head()
```

#### Out[29]:

area	features/FFMC	
10.820000	96.099998	0
24.590000	90.500000	1
0.170000	94.300003	2
14.680000	96.099998	3
88.489998	92.900002	4

8.010956 4137.2344 ]]

#### In [30]:

] ]

```
df_normalizer = tf.keras.layers.Normalization()
df_normalizer.adapt(X)
print(df_normalizer.mean.numpy())
print(df_normalizer.variance.numpy())
[[91.26317 13.101703]]
```

1. Используя созданный нормализующий слой, постройте нейронную сеть (нелинейный регресор) с количеством скрытых слоев, количеством нейронов и функцией активации, указанными в индивидуальном задании, и одним нейроном в выходном слое и обучите ее на наборе данных из двух признаков и отклика.

Параметры глубокой нейронной сети: кол-во скрытых слоев – 3, кол-во нейронов в скрытом слое – 128, функция активации – relu.

#### In [31]:

```
model = Sequential([
    df_normalizer,
    Dense(units=128, activation='relu'),
    Dense(units=128, activation='relu'),
    Dense(units=128, activation='relu'),
    Dense(units=1, activation='linear')
])
```

### In [32]:

```
model.summary()
```

Model: "sequential 2"

Layer (type)	Output Shape	Param #				
normalization (Normalization)	(None, 2)	5				
dense_2 (Dense)	(None, 128)	384				
dense_3 (Dense)	(None, 128)	16512				
dense_4 (Dense)	(None, 128)	16512				
dense_5 (Dense)	(None, 1)	129				
Total params: 33,542 Trainable params: 33,537 Non-trainable params: 5						

In [33]:

```
model.compile(loss='mse')
history = model.fit(
    X, y,
    epochs=100,
    # уровень выводимой информации
    verbose=1,
    # проверка (валидация) на 20% обучающих данных
    validation_split = 0.2)
```

```
Epoch 1/100
41
Epoch 2/100
Epoch 3/100
Epoch 4/100
Epoch 5/100
Epoch 6/100
Epoch 7/100
Epoch 8/100
Epoch 9/100
Epoch 10/100
Epoch 11/100
Epoch 12/100
Epoch 13/100
Epoch 14/100
Epoch 15/100
Epoch 16/100
Epoch 17/100
Epoch 18/100
Epoch 19/100
Epoch 20/100
Epoch 21/100
Epoch 22/100
Epoch 23/100
Epoch 24/100
Epoch 25/100
Epoch 26/100
Epoch 27/100
Epoch 28/100
Epoch 29/100
Epoch 30/100
Epoch 31/100
```

```
Epoch 32/100
Epoch 33/100
Epoch 34/100
Epoch 35/100
Epoch 36/100
Epoch 37/100
Epoch 38/100
Epoch 39/100
Epoch 40/100
Epoch 41/100
Epoch 42/100
Epoch 43/100
Epoch 44/100
Epoch 45/100
Epoch 46/100
Epoch 47/100
Epoch 48/100
Epoch 49/100
Epoch 50/100
Epoch 51/100
Epoch 52/100
Epoch 53/100
Epoch 54/100
Epoch 55/100
Epoch 56/100
Epoch 57/100
Epoch 58/100
Epoch 59/100
Epoch 60/100
Epoch 61/100
Epoch 62/100
Epoch 63/100
Epoch 64/100
Epoch 65/100
Epoch 66/100
Epoch 67/100
```

```
Epoch 68/100
Epoch 69/100
Epoch 70/100
Epoch 71/100
Epoch 72/100
Epoch 73/100
Epoch 74/100
Epoch 75/100
Epoch 76/100
Epoch 77/100
Epoch 78/100
Epoch 79/100
Epoch 80/100
Epoch 81/100
Epoch 82/100
Epoch 83/100
Epoch 84/100
Epoch 85/100
Epoch 86/100
Epoch 87/100
Epoch 88/100
Epoch 89/100
Epoch 90/100
Epoch 91/100
Epoch 92/100
Epoch 93/100
Epoch 94/100
Epoch 95/100
Epoch 96/100
Epoch 97/100
Epoch 98/100
Epoch 99/100
Epoch 100/100
```

```
    визуализируите павор даппых в виде точечного графика и прогноз пеиропнои сети в виде поверхности в

   трехмерном пространстве.
In [34]:
y pred = model.predict(X)
16/16 [======== ] - Os 2ms/step
In [35]:
y_pred = [x[0] for x in y_pred]
In [36]:
X = np.array(X)
Χ
Out[36]:
array([[96.1 , 10.82],
      [90.5 , 24.59],
      [94.3 , 0.17],
       [90. , 0. ],
       [89.4, 0.],
       [91.6 , 42.87]], dtype=float32)
In [40]:
n plot = 51
x_plot = np.linspace(np.min(xs), np.max(xs), n_plot)
y_plot = np.linspace(np.min(ys), np.max(ys), n_plot)
x_plot, y_plot = np.meshgrid(x_plot, y_plot)
In [41]:
x_plot2 = np.reshape(x_plot, [n_plot**2,1])
y plot2 = np.reshape(y plot, [n plot**2,1])
xy 2 = np.hstack([x plot2, y plot2])
xy_2.shape
Out[41]:
(2601, 2)
In [43]:
z = model.predict(xy 2)
z.shape
82/82 [======== ] - Os 1ms/step
Out[43]:
(2601, 1)
In [46]:
z_plot = z.reshape((n_plot, n_plot))
In [52]:
from matplotlib import cm
fig = plt.figure(figsize=(12, 8))
ax = fig.add subplot(111, projection='3d')
```

rstride=1, cstride=1, linewidth=0.05, cmap=cm.winter, antialiased=True, \


surf = ax.plot surface(x plot, y plot, z plot, \

```
edgecolors='gray')
ax.scatter(xs, ys, zs, s=100, c='r')

ax.set_xlabel('features/FFMC', fontsize=14)
ax.set_ylabel('area', fontsize=14)
ax.set_zlabel('features/temp', fontsize=14)
ax.set_title('Зависимость параметров лесных пожаров', fontsize=16)

ax.set_zlim(0., z_plot.max())
ax.view_init(elev = 20, azim = 120)
```

# Зависимость параметров лесных пожаров



1. Разбейте набор данных из двух признаков и отклика на обучающую и тестовую выборки и постройте кривые обучения для заданного показателя качества в зависимости от количества точек в обучающей выборке, подписывая оси и рисунок и создавая легенду.

Показатель качества регрессии - MSE (mean squared error)

#### In [91]:

```
def data_split(ratio=20):
    train, test = tfds.load("forest_fires", split= [f'train[:{ratio}%]', f'train[{ratio}%:
]'])
    train = tfds.as_dataframe(train)
    test = tfds.as_dataframe(test)
    y_train = train['features/temp']
    y_test = test['features/temp']
    X_train = train[['features/FFMC', 'area']]
    X_test = test[['features/FFMC', 'area']]
    return X_train, y_train, X_test, y_test
```

```
In [92]:
def mse(y, y):
 return np.sum((y - y )**2) / y.shape[0]
In [101]:
train score = []
test score = []
for i in range(10, 100, 10):
 X_train, y_train, X_test, y_test = data_split(i)
 print(X_train.shape, y_train.shape)
 model = Sequential([
    df normalizer,
    Dense(units=128, activation='relu'),
     # Dense(units=128, activation='relu'),
     # Dense(units=128, activation='relu'),
    Dense(units=1, activation='linear')
 1)
 model .compile(loss='mse')
 model .fit(X train, y train, epochs=50, verbose=0)
 y train predict = model .predict(X train)
 y train predict = [x[0] for x in y train predict]
 train score.append(mse(y train, y train predict))
 y test predict = model .predict(X test)
 y test predict = [x[0] for x in y test predict]
 test_score.append(mse(y_test, y_test_predict))
 print('-->', i, ' done')
(52, 2) (52,)
2/2 [======] - Os 10ms/step
15/15 [========= ] - Os 2ms/step
--> 10 done
(103, 2) (103,)
4/4 [========] - 0s 4ms/step
13/13 [======== ] - Os 1ms/step
--> 20 done
(155, 2) (155,)
5/5 [=======] - Os 2ms/step
12/12 [======== ] - Os 2ms/step
--> 30 done
(207, 2) (207,)
7/7 [======] - 0s 2ms/step
10/10 [======= ] - Os 2ms/step
--> 40 done
(258, 2) (258,)
9/9 [=======] - 0s 2ms/step
9/9 [=======] - Os 2ms/step
--> 50 done
(310, 2) (310,)
10/10 [=======] - Os 2ms/step
7/7 [=======] - 0s 2ms/step
--> 60 done
(362, 2) (362,)
12/12 [=======] - Os 1ms/step
5/5 [======] - 0s 2ms/step
--> 70 done
(414, 2) (414,)
13/13 [======== ] - Os 1ms/step
4/4 [======== ] - 0s 4ms/step
--> 80 done
(465, 2) (465,)
15/15 [======== ] - Os 2ms/step
2/2 [=======] - Os 8ms/step
```


--> 90 done

In [104]:

```
range(10, 100, 10),
train_score, label='train'
)
plt.plot(
range(10, 100, 10),
test_score, label='test'
)
plt.xlabel('% of data')
plt.ylabel('mse')
plt.title('Кривые обучения')
plt.legend()
```

## Out[104]:

<matplotlib.legend.Legend at 0x7fea0b804ee0>



## In [ ]:

In [ ]: