# РОССИЙСКИЙ УНИВЕРСИТЕТ ДРУЖБЫ НАРОДОВ

Факультет физико-математических и естественных наук

Кафедра информационных технологий

# ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 5

Дисциплина: Методы машинного обучения

Студент: Шалыгин Георгий

Группа: НФИ-02

# **Москва 2023**

## Вариант № 15

1. При помощи модуля pandas\_datareader считайте котировки указанной в индивидуальным задании акции за указанный период времени.

Считайте котировки акции с указанным ниже тикером за 2018-2019 год:

### **KO Coca-Cola Company**

aapl = pdr.get data yahoo('KO',

aapl.head()

```
In [ ]:
#!pip install yfinance
In [1]:
import numpy as np
import matplotlib as mpl
import matplotlib.pyplot as plt
import pandas as pd
import tensorflow as tf
tf. version
Out[1]:
'2.12.0'
In [2]:
from pandas datareader import data as pdr
import yfinance as yfin
import datetime as dt
yfin.pdr override()
In [3]:
```

start=dt.datetime(2018, 1, 1), end=dt.datetime(2019, 1, 1))

	Open	High	Low	Close	Adj Close	Volume
Date						
2018-01-02	45.910000	45.939999	45.509998	45.540001	38.548206	10872200
2018-01-03	45.490002	45.689999	45.340000	45.439999	38.463558	12635600
2018-01-04	45.560001	46.220001	45.450001	46.080002	39.005295	12709400
2018-01-05	46.020000	46.200001	45.790001	46.070000	38.996834	13113100
2018-01-08	45.950001	46.099998	45.880001	46.000000	38.937584	7068600

## In [4]:

```
aapl.tail()
```

### Out[4]:

	Open	High	Low	Close	Adj Close	Volume
Date						
2018-12-24	47.619999	47.869999	45.830002	45.959999	40.249268	10733700
2018-12-26	45.880001	46.959999	45.660000	46.939999	41.107498	14342600
2018-12-27	46.740002	47.549999	46.029999	47.529999	41.624199	16966500
2018-12-28	47.889999	48.009998	47.029999	47.200001	41.335190	13218200
2018-12-31	47.490002	47.540001	46.959999	47.349998	41.466545	10576300


**1.** Визуализируйте котировки акции (столбец Adj Close) за весь период на графике. Подпишите оси и рисунок.

## In [6]:

```
data = aapl['Adj Close']
plt.plot(data)
plt.xlabel('date')
plt.ylabel('Adj Close')
plt.title('Котировки акций cocacola')
```

## Out[6]:

Text(0.5, 1.0, 'Котировки акций cocacola')



```
36
  2018-01
           2018-03
                    2018-05
                              2018-07
                                        2018-09
                                                 2018-11
                                                           2019-01
                                date
```

1. Вычислите и визуализируйте заданный показатель акции в соответствии с индивидуальным заданием.

Показатель акции: дневной убыток, способ визуализации – диаграмма размаха


#### In [7]:

```
diff = np.append(np.array(data), 0) - np.insert(np.array(data), 0, [0])
diff *= -1
diff = diff[1:-1]
pd.Series (diff).plot.box(title='Дневной убыток')
```

#### Out[7]:

<Axes: title={'center': 'Дневной убыток'}>

# Дневной убыток 0 0



1. Сформируйте обучающую, тестовую и валидационные выборки для обучения нейронной сети в соответствии с индивидуальным заданием.

Прогнозирование стоимости акции через 12 дней по данным за предыдущие 25 дней.

## In [8]:

```
adj = aapl['Adj Close']
raw data = aapl.drop(['Adj Close'], axis=1)
```

# In [9]:

```
num train samples = int(0.5 * len(raw data))
num val samples = int(0.25 * len(raw data))
num test samples = len(raw data) - num train samples - num val samples
print("num train samples:", num train samples)
print("num val samples:", num val samples)
print("num_test_samples:", num_test_samples)
```

```
num train samples: 125
num val samples: 62
num test samples: 64
```

```
In [10]:
```

```
# mean = raw data[:num train samples].mean(axis=0)
# raw data -= mean
# std = raw data[:num train samples].std(axis=0)
# raw data /= std # whole raw data normalized w.r.t. first num train samples rows
# mean.shape, std.shape
```

#### In [11]:

```
sampling rate = 1
sequence_length = 25
delay = \overline{25} + 12 - 1
batch size = 256
train dataset = tf.keras.utils.timeseries dataset from array(
    raw data[:-delay],
   targets=adj[delay:],
    sampling rate=sampling rate,
    sequence length=sequence_length,
    shuffle=True,
   batch size=batch size,
    start index=0,
    end index=num train samples)
val dataset = tf.keras.utils.timeseries dataset from array(
    raw data[:-delay],
    targets=adj[delay:],
    sampling rate=sampling rate,
    sequence length=sequence length,
    shuffle=True,
   batch size=batch size,
    start index=num train samples,
    end index=num train samples + num val samples)
test dataset = tf.keras.utils.timeseries dataset from array(
   raw data[:-delay],
   targets=adj[delay:],
    sampling rate=sampling rate,
    sequence length=sequence length,
    shuffle=True,
    batch size=batch size,
    start index=num train samples + num val samples)
```

1. Постройте нейронную сеть MLP с нормализующим слоем и одним плотным скрытым слоем из 16 нейронов для прогнозирования стоимости акции и обучите ее на обучающей выборке. Оцените качество прогнозирования при помощи заданного показателя качества на тестовой выборке.

Показатель качества МАЕ

```
In [12]:
df normalizer = tf.keras.layers.Normalization()
df normalizer.adapt(raw data)
print(df_normalizer.mean.numpy())
print(df normalizer.variance.numpy())
[[4.5413548e+01\ 4.5724541e+01\ 4.5099438e+01\ 4.5409920e+01\ 1.2525482e+07]]
[[4.4421110e+00 4.5318952e+00 4.3046637e+00 4.4931951e+00 1.7014095e+13]]
In [90]:
```

```
inputs = tf.keras.Input(shape=(sequence length, raw data.shape[-1]))
x = df normalizer(inputs)
x = tf.keras.layers.Flatten()(x)
x = tf.keras.layers.Dense(16, activation="relu")(x)
outputs = tf.keras.layers.Dense(1)(x)
model = tf.keras.Model(inputs, outputs)
```

```
model.summary()
model.compile(optimizer=tf.keras.optimizers.Adam(0.1), loss="mse", metrics=["mae"])
history = model.fit(train dataset,
          epochs=50,
          validation data=val dataset,
print(f"Test MAE: {model.evaluate(test dataset)[1]:.2f}")
Model: "model 18"
Layer (type)
              Output Shape
                           Param #
______
input 20 (InputLayer)
              [(None, 25, 5)]
normalization (Normalizatio (None, 25, 5)
                            11
n)
flatten 10 (Flatten) (None, 125)
dense 41 (Dense)
               (None, 16)
                            2016
dense 42 (Dense)
               (None, 1)
                            17
Total params: 2,044
Trainable params: 2,033
Non-trainable params: 11
Epoch 1/50
loss: 1972.3865 - val mae: 44.3707
Epoch 2/50
l loss: 2055.7756 - val mae: 45.3129
Epoch 3/50
l loss: 1933.4203 - val mae: 43.9533
Epoch 4/50
loss: 1694.0490 - val mae: 41.1207
Epoch 5/50
loss: 1399.2942 - val mae: 37.3062
Epoch 6/50
loss: 1086.6844 - val mae: 32.7129
Epoch 7/50
l loss: 803.0599 - val mae: 27.7929
oss: 575.3167 - val mae: 22.9462
Epoch 9/50
loss: 413.0074 - val mae: 18.5405
```

Epoch 10/50

Epoch 11/50

Epoch 12/50

Epoch 13/50

Epoch 14/50

loss: 310.3462 - val mae: 15.3304

l loss: 252.3762 - val mae: 13.9358

oss: 223.1028 - val mae: 13.4129


oss: 209.7725 - val mae: 13.1315


loss: 203.8006 - val mae: 12.9653

```
Epoch 15/50
loss: 201.2509 - val mae: 12.8690
Epoch 16/50
l loss: 200.1558 - val mae: 12.8077
Epoch 17/50
loss: 199.5119 - val mae: 12.7557
Epoch 18/50
oss: 198.8014 - val mae: 12.6995
Epoch 19/50
oss: 198.0558 - val mae: 12.6415
Epoch 20/50
oss: 197.3218 - val mae: 12.5873
Epoch 21/50
loss: 196.6581 - val mae: 12.5339
Epoch 22/50
oss: 196.2396 - val mae: 12.4887
Epoch 23/50
oss: 195.8798 - val mae: 12.4471
Epoch 24/50
oss: 195.5004 - val mae: 12.4070
Epoch 25/50
loss: 195.0046 - val mae: 12.3643
Epoch 26/50
loss: 194.3437 - val mae: 12.3130
Epoch 27/50
loss: 193.8077 - val mae: 12.2627
Epoch 28/50
oss: 193.5300 - val mae: 12.2180
Epoch 29/50
loss: 193.5132 - val mae: 12.1799
Epoch 30/50
oss: 193.4114 - val mae: 12.1410
Epoch 31/50
oss: 193.1207 - val mae: 12.0885
loss: 192.5210 - val mae: 12.0159
Epoch 33/50
loss: 191.2669 - val mae: 11.9047
Epoch 34/50
oss: 189.3012 - val mae: 11.7674
Epoch 35/50
loss: 187.0116 - val mae: 11.6020
Epoch 36/50
loss: 185.5043 - val mae: 11.4361
Epoch 37/50
loss: 185.2414 - val mae: 11.2861
Epoch 38/50
oss: 185.9741 - val mae: 11.1683
```

```
Epoch 39/50
loss: 187.5298 - val mae: 11.1186
Epoch 40/50
oss: 189.0164 - val mae: 11.0992
Epoch 41/50
loss: 189.9563 - val mae: 11.1026
Epoch 42/50
loss: 190.8377 - val mae: 11.1273
Epoch 43/50
loss: 192.5115 - val mae: 11.1775
Epoch 44/50
loss: 195.7293 - val mae: 11.2703
Epoch 45/50
loss: 200.0051 - val mae: 11.3925
Epoch 46/50
oss: 202.6202 - val mae: 11.4802
Epoch 47/50
oss: 203.6814 - val mae: 11.5357
Epoch 48/50
oss: 203.5324 - val mae: 11.5622
Epoch 49/50
oss: 202.6252 - val mae: 11.5646
Epoch 50/50
oss: 201.3511 - val mae: 11.5470
Test MAE: 16.22
In [91]:
loss = history.history["mae"]
val loss = history.history["val mae"]
epochs = range(1, len(loss) + 1)
plt.figure()
plt.plot(epochs[1:], loss[1:], "bo", label="МАЕ на обучающей выборке")
plt.plot(epochs, val loss, "b", label="МАЕ на валидационной выборке")
plt.title("Ошибка M\overline{AE} на обучающей и валидационной выборках")
plt.legend()
plt.show()
```

# Ошибка МАЕ на обучающей и валидационной выборках





1. Примените указанную в индивидуальном задании технику решения проблемы исчезающих градиентов и постройте нейронную сеть MLP с нормализующим слоем и тремя плотными скрытыми слоями из 16 нейронов для прогнозирования стоимости акции и обучите ее на обучающей выборке. Оцените качество прогнозирования при помощи заданного показателя качества для тестовой выборки.

Техника борьбы с исчезающими градиентами: Функции активации без насыщения

#### In [92]:

```
inputs2 = tf.keras.Input(shape=(sequence length, raw data.shape[-1]))
x2 = tf.keras.layers.Flatten()(inputs2)
x2 = tf.keras.layers.Dense(16, activation="selu")(x2)
x2 = tf.keras.layers.Dense(16, activation="selu")(x2)
x2 = tf.keras.layers.Dense(16, activation="selu")(x2)
outputs2 = tf.keras.layers.Dense(1)(x2)
model2 = tf.keras.Model(inputs2, outputs2)
model2.summary()
model2.compile(optimizer=tf.keras.optimizers.Adam(0.08), loss="mse", metrics=["mae"])
history2 = model2.fit(train dataset,
                    epochs=50,
                    validation data=val dataset,
print(f"Test MAE: {model2.evaluate(test dataset)[1]:.2f}")
```

Model: "model 19"

Layer (type)	Output Shape	Param #
input_21 (InputLayer)	[(None, 25, 5)]	0
flatten_11 (Flatten)	(None, 125)	0
dense_43 (Dense)	(None, 16)	2016
dense_44 (Dense)	(None, 16)	272
dense_45 (Dense)	(None, 16)	272
dense_46 (Dense)	(None, 1)	17
Total params: 2,577		

Trainable params: 2,577

Non-trainable params: 0

```
Epoch 1/50
57.0000 - val loss: 64973191512064.0000 - val mae: 8050021.0000
Epoch 2/50
10098205.0000 - val loss: 291651518464.0000 - val mae: 525309.1875
30.9375 - val loss: 326845530112.0000 - val mae: 561682.2500
Epoch 4/50
072.6250 - val loss: 145038160.0000 - val mae: 3300.7517
42 - val loss: 1391.9651 - val mae: 37.3050
Epoch 6/50
1 1000 1220 1662 - ++11 mag. 26 1200
```


```
1 1055: 1320.1003 - Val Mae: 30.4333
Epoch 7/50
l loss: 1310.5618 - val mae: 36.1976
Epoch 8/50
al loss: 1304.2726 - val mae: 36.1106
Epoch 9/50
al loss: 1297.2444 - val mae: 36.0131
Epoch 10/50
al_loss: 1285.5486 - val_mae: 35.8504
Epoch 11/50
l loss: 1261.8826 - val mae: 35.5188
Epoch 12/50
al loss: 1229.4293 - val mae: 35.0590
Epoch 13/50
al loss: 1188.0408 - val mae: 34.4636
Epoch 14/50
l loss: 1135.8031 - val mae: 33.6972
Epoch 15/50
l loss: 1073.1824 - val mae: 32.7549
Epoch 16/50
loss: 998.3251 - val mae: 31.5915
Epoch 17/50
loss: 907.0637 - val mae: 30.1125
Epoch 18/50
loss: 810.2496 - val mae: 28.4596
Epoch 19/50
l loss: 708.1492 - val mae: 26.6055
Epoch 20/50
l loss: 597.4759 - val mae: 24.4372
Epoch 21/50
l loss: 488.4710 - val mae: 22.0946
Epoch 22/50
1_loss: 384.9294 - val_mae: 19.6120
Epoch 23/50
1_loss: 287.7568 - val_mae: 16.9546
Epoch 24/50
loss: 200.9949 - val mae: 14.1667
Epoch 25/50
l loss: 127.6983 - val mae: 11.2871
Epoch 26/50
oss: 70.2199 - val mae: 8.3619
Epoch 27/50
oss: 29.9517 - val mae: 5.4454
Epoch 28/50
ss: 7.0660 - val mae: 2.6013
Epoch 29/50
ss: 0.3087 - val_mae: 0.4420
Epoch 30/50
```

000 · 6 0420 - ++11 mag. 2 5776


```
USS: 0.7427 - Val mae: 2.3//0
Epoch 31/50
oss: 22.9541 - val mae: 4.7597
Epoch 32/50
loss: 43.5774 - val mae: 6.5786
Epoch 33/50
oss: 64.0658 - val mae: 7.9854
Epoch 34/50
l loss: 80.4741 - val mae: 8.9541
Epoch 35/50
loss: 90.2068 - val mae: 9.4820
Epoch 36/50
l loss: 92.2030 - val mae: 9.5867
Epoch 37/50
l loss: 86.7999 - val mae: 9.3006
Epoch 38/50
loss: 75.4022 - val mae: 8.6662
Epoch 39/50
loss: 60.0852 - val mae: 7.7322
Epoch 40/50
l loss: 43.2083 - val mae: 6.5505
Epoch 41/50
oss: 27.0848 - val mae: 5.1755
Epoch 42/50
loss: 13.7919 - val mae: 3.6733
Epoch 43/50
oss: 4.7475 - val mae: 2.1091
Epoch 44/50
loss: 0.5717 - val mae: 0.5958
Epoch 45/50
ss: 1.3709 - val mae: 1.0481
Epoch 46/50
ss: 6.6165 - val mae: 2.5135
Epoch 47/50
oss: 15.2496 - val mae: 3.8666
Epoch 48/50
ss: 25.8399 - val mae: 5.0538
Epoch 49/50
oss: 36.4113 - val mae: 6.0094
Epoch 50/50
oss: 46.3430 - val mae: 6.7856
Test MAE: 10.08
```

# In [93]:

```
loss = history2.history["mae"]
val_loss = history2.history["val_mae"]
epochs = range(1, len(loss) + 1)
plt.figure()
plt.plot(epochs[1:], loss[1:], "bo", label="MAE на обучающей выборке")
plt.plot(epochs, val_loss, "b", label="MAE на валидационной выборке")
```



# Ошибка МАЕ на обучающей и валидационной выборках



1. Постройте рекуррентную нейронную сеть с нормализующим слоем и одним скрытым слоем LSTM из 16 нейронов для прогнозирования стоимости акции и обучите ее на обучающей выборке. Оцените качество прогнозирования при помощи заданного показателя качества на тестовой выборке.

### In [94]:

Model: "model 20"

Layer (type)	Output Shape	Param #
input_22 (InputLayer)	[(None, 25, 5)]	0
normalization (Normalization)	(None, 25, 5)	11
lstm_10 (LSTM)	(None, 16)	1408
dense_47 (Dense)	(None, 1)	17

\_\_\_\_\_

Total params: 1,436 Trainable params: 1,425 Non-trainable params: 11

```
Epoch 1/50
loss: 1590.6273 - val mae: 39.8801
Epoch 2/50
al loss: 1578.7134 - val mae: 39.7256
Epoch 3/50
al loss: 1454.3834 - val mae: 38.0916
Epoch 4/50
al loss: 1318.6726 - val mae: 36.2270
Epoch 5/50
al loss: 1233.3102 - val mae: 34.9992
Epoch 6/50
l loss: 1168.3997 - val mae: 34.0276
Epoch 7/50
loss: 1109.8286 - val mae: 33.1306
Epoch 8/50
l loss: 1074.9391 - val mae: 32.5403
Epoch 9/50
1 loss: 1025.9694 - val_mae: 31.7310
Epoch 10/50
l loss: 978.9792 - val mae: 30.9299
Epoch 11/50
l loss: 933.4806 - val mae: 30.1296
Epoch 12/50
l loss: 889.0944 - val mae: 29.3247
Epoch 13/50
l loss: 822.1046 - val mae: 28.1565
Epoch 14/50
loss: 728.8238 - val mae: 26.5222
Epoch 15/50
l loss: 671.1282 - val mae: 25.4225
Epoch 16/50
l loss: 610.9203 - val mae: 24.2240
Epoch 17/50
l loss: 568.8328 - val mae: 23.3102
Epoch 18/50
l loss: 528.9741 - val mae: 22.4129
Epoch 19/50
l_loss: 491.0657 - val_mae: 21.5265
Epoch 20/50
l loss: 457.6025 - val mae: 20.7155
Epoch 21/50
l loss: 425.1559 - val mae: 19.9098
Epoch 22/50
l loss: 363.3733 - val mae: 18.5662
Epoch 23/50
l loss: 336.7281 - val mae: 17.8174
Epoch 24/50
```

l loss: 314.1085 - val mae: 17.1359


```
Epoch 25/50
l loss: 293.7347 - val mae: 16.4961
Epoch 26/50
loss: 274.8857 - val mae: 15.8647
Epoch 27/50
l loss: 256.9485 - val mae: 15.2339
Epoch 28/50
l loss: 242.0242 - val mae: 14.6694
Epoch 29/50
loss: 227.1814 - val mae: 14.0856
Epoch 30/50
loss: 212.4329 - val mae: 13.4913
Epoch 31/50
loss: 199.1187 - val mae: 12.9224
Epoch 32/50
loss: 187.5295 - val mae: 12.3883
Epoch 33/50
loss: 177.3641 - val mae: 11.8833
Epoch 34/50
loss: 168.0582 - val mae: 11.3956
Epoch 35/50
loss: 159.4341 - val mae: 10.9249
loss: 151.7893 - val mae: 10.4815
Epoch 37/50
loss: 145.3031 - val mae: 10.0721
Epoch 38/50
loss: 139.9293 - val mae: 9.6956
Epoch 39/50
loss: 135.5469 - val mae: 9.3431
Epoch 40/50
oss: 132.2924 - val mae: 9.0150
Epoch 41/50
oss: 130.5797 - val mae: 8.7228
Epoch 42/50
oss: 130.4935 - val mae: 8.4712
Epoch 43/50
oss: 131.4650 - val_mae: 8.2538
Epoch 44/50
oss: 132.7609 - val mae: 8.0598
Epoch 45/50
oss: 133.9584 - val mae: 7.8822
Epoch 46/50
oss: 134.8031 - val mae: 7.7156
Epoch 47/50
oss: 135.2086 - val mae: 7.5569
Epoch 48/50
```

oss: 135.2697 - val mae: 7.4066

#### In [95]:

```
loss = history3.history["mae"]
val_loss = history3.history["val_mae"]
epochs = range(1, len(loss) + 1)
plt.figure()
plt.plot(epochs[1:], loss[1:], "bo", label="MAE на обучающей выборке")
plt.plot(epochs, val_loss, "b", label="MAE на валидационной выборке")
plt.title("Ошибка МАЕ на обучающей и валидационной выборках")
plt.legend()
plt.show()
```

# Ошибка МАЕ на обучающей и валидационной выборках




**1.** Визуализируйте кривые обучения для трех построенных моделей на одном рисунке в зависимости от эпохи обучения, подписывая оси и рисунок и создавая легенду. Используйте для визуализации относительную ошибку (ошибку обучения, деленную на начальную ошибку на первой эпохе).

### In [98]:

```
loss1 = np.array(history.history["mae"]) / history3.history["mae"][0]
val_loss1 = np.array(history.history["val_mae"]) / history3.history["val_mae"][0]
loss2 = np.array(history2.history["mae"]) / history2.history["mae"][1]
val_loss2 = np.array(history2.history["val_mae"]) / history2.history["val_mae"][0]
loss3 = np.array(history3.history["mae"]) / history3.history["mae"][0]
val_loss3 = np.array(history3.history["val_mae"]) / history3.history["val_mae"][0]
epochs = range(1, len(loss1) + 1)
plt.figure(figsize=(12,8))
plt.scatter(epochs[1:], loss1[1:], label="MAE на обучающей выборке MLP")
plt.plot(epochs, val_loss1, label="MAE на валидационной выборке MLP")
plt.scatter(epochs[1:], loss2[1:], label="MAE на обучающей выборке MLP 2.0")
plt.scatter(epochs, val_loss2, label="MAE на валидационной выборке LSTM")
plt.scatter(epochs, val_loss3, label="MAE на валидационной выборке LSTM")
```

```
plt.xlabel('Epoch')
plt.ylabel('Relativ order')
plt.title("Ошибка МАЕ на обучающей и валидационной выборках")
plt.legend()
plt.show()
```

## Ошибка МАЕ на обучающей и валидационной выборках



1. Визуализируйте весь набор данных и прогнозы трех построенных моделей для обучающей и тестовой выборок на одном рисунке (ось X - даты, ось Y - стоимость акции), подписывая оси и рисунок и создавая легенду.

```
In [99]:
real = np.array(aapl['Adj Close'])[-191:]
In [100]:
real.shape
Out[100]:
(191,)
In [101]:
all_data = tf.keras.utils.timeseries_dataset_from_array(
    raw data[:-delay],
    targets=adj[delay:],
    sampling_rate=sampling rate,
    sequence_length=sequence_length,
```

```
In [102]:
```

shuffle=True, batch size=1000, start index=0)

```
for a, b in all data:
```

```
samples = a
targ = b
```

## In [103]:


```
6/6 [=======] - 0s 3ms/step
6/6 [======] - 0s 3ms/step
6/6 [======] - 0s 4ms/step
```

### In [104]:

```
plt.plot(real, label='real')
plt.plot(y1, label='mlp1')
plt.plot(y2, label='mlp2')
plt.plot(y3, label='rnn')
plt.xlabel('day')
plt.xlabel('adj.')
plt.xlabel('adj.')
plt.title('Регрессия котировок акций')
plt.legend()
```

## Out[104]:

<matplotlib.legend.Legend at 0x7f84af7c1420>



### In [ ]: